




شناسایی آماری الگو و یادگیری ماشین

جلسه دوم: تئوری و پیاده‌سازی PCA




PCA < ①
②

صورت مسئله

PCA

پیرامتری
بدون ناظر



$$C_3 = \begin{Bmatrix} x_3 \\ y_3 \end{Bmatrix}$$

Data = X =
↓
?

$$\begin{bmatrix} x_1 & x_2 & x_3 \\ y_1 & y_2 & y_3 \end{bmatrix}$$

پایگاه داده

کیفیت دوربین

نزیر
↓
↑
رض

؟ - تکرار بدون اطلاعات (redundancy) - لغزش ؟

تئوری الگوریتم PCA (تجزیه مولفه‌های اساسی) جهت کاهش بعد - دیدگاه اول

$$\boxed{\text{var}} = \frac{1}{N} \vec{a} \vec{a}^T$$

$$\vec{a} = \begin{bmatrix} a_1 \\ a_2 \\ \vdots \\ a_n \end{bmatrix}, \vec{b} = \begin{bmatrix} b_1 \\ b_2 \\ \vdots \\ b_n \end{bmatrix}$$

$$\text{cov} = \frac{1}{N} \vec{a} \vec{b}^T$$

جدی

$$\begin{pmatrix} x_1 \\ y_1 \\ x_2 \\ y_2 \\ x_3 \\ y_3 \end{pmatrix}$$

$$\Rightarrow \text{Cov}(X) = \frac{1}{N} X X^T =$$

$$\begin{pmatrix} \text{var}(x_1) & \text{cov}(x_1, y_1) & \dots & \text{cov}(x_1, y_3) \\ \text{cov}(y_1, x_1) & \text{var}(y_1) & \dots & \text{cov}(y_1, y_3) \\ \vdots & \vdots & \ddots & \vdots \\ \text{cov}(y_3, x_1) & \dots & \dots & \text{var}(y_3) \end{pmatrix}$$

متناظر

$$\text{cov}(x_1, y_1) = \text{cov}(y_1, x_1)$$

$$\Rightarrow X_n = X - \mu \Rightarrow m = 0$$

①

$$C_X = XX^T$$

$$Cov(x_1, x_1)$$

$$\vdots$$

$$Cov(x_2, x_2)$$

$$\Rightarrow C_X = \begin{pmatrix} \diagup & 0 \\ 0 & \diagdown \end{pmatrix}$$

$$\|u\| = 1$$

$$norm(u) = 1$$

$$u = \begin{bmatrix} | & | & | & \dots \end{bmatrix}$$

بردارها درجه ۰:

$$u^T u = 1$$

$$\sqrt{u^T u} = 1$$

$$\lambda = \begin{bmatrix} \ominus & 0 & 0 & \dots \\ 0 & \ominus & 0 & \dots \\ 0 & 0 & \ominus & \dots \\ \vdots & \vdots & \vdots & \ddots \end{bmatrix}$$

مقادیر درجه ۰:



②

$$C_X = u^T \lambda u$$

مقادیر درجه ۰، بردارها درجه ۰

$$y = w^T x X$$

③

$$y = u^T \cdot X \rightarrow C_Y = \begin{pmatrix} \diagup & 0 \\ 0 & \diagdown \end{pmatrix}$$

$$y = u^T \cdot X, C_Y = yy^T = (u^T X)(u^T X)^T = u^T X X^T u = u^T (u^T \lambda u) u$$

$$C_Y = \underbrace{u^T u} \lambda \underbrace{u^T u} = 1 \times \lambda \times 1 = \boxed{\lambda} \quad C_X = u^T \lambda u \rightarrow \begin{pmatrix} \diagup & 0 \\ 0 & \diagdown \end{pmatrix}$$

$\lambda = 0 \rightarrow X = X - m \rightarrow \mu = 0$

①

$C_X = X X^T$

$X = d \times N$

تعداد نمونه ها

$C_X = u^T \cdot \lambda \cdot u$

$y = u^T \cdot X$

$d \times d$

$d \times N$

$C_y = \begin{pmatrix} \lambda^2 \\ 0 \end{pmatrix}$

$d \times N$

$\Rightarrow u =$



تعداد بُعد فضایی جدید

$m < d$


$\Rightarrow y = \underbrace{u^T}_{(d \times m)^T} \cdot \underbrace{X}_{d \times N} = (m \times d) \times (d \times N) = m \times N$

$m < d$

کمتر کاهش بعد

$$[u_1 \ u_2 \ \dots \ u_d]$$

تئوری الگوریتم PCA (تجزیه مولفه‌های اساسی) جهت کاهش بعد - دیدگاه دوم



↓
 $x \rightarrow C_x \rightarrow u^T x u \rightarrow \boxed{y = u^T x} \rightarrow C_y = \begin{pmatrix} 1 \\ 0 \end{pmatrix}$
 پراکنش → max → ?
 تبدیل → تقویر → ضعیف
 نیست

max → جتن → ضعیف
 ↓
 $y = ax + b$
 ↓
 ?

← پیداکردن یک خط


$$j_1 = \max_{u_1} \text{Var}(u_1^T X) \Rightarrow j = \arg \max_{u_1} \left(\text{Var}(u_1^T X) \right)$$

مازهم

$X = 2 \times N$
 ↓
 تعداد ویژگی
 تعداد نمونه

$$j = \underset{u_1}{\operatorname{argmax}} \left(\underset{1 \times 1}{\operatorname{var}(u_1^T X)} \right) = \underset{u_1}{\operatorname{argmax}} \left(\underset{d \times 1}{u_1^T} \underset{d \times d}{S} \underset{d \times 1}{u_1} \right) = \underset{1 \times 1}{\lambda_1}$$

$$S = XX^T$$



$$\frac{\partial j}{\partial u_1} = 0 \Rightarrow u_1 = u_{opt}$$

$$\Rightarrow \frac{\partial j}{\partial u_1} = 0 \Rightarrow 2Su_1 = 0 \Rightarrow \boxed{u=0}$$

نیرمنز $\Rightarrow \boxed{u_1^T u_1 = 1}$ → تغییر

مقیه $\Rightarrow \boxed{u_1 \neq 0}$

$$\Rightarrow j = u_1^T S u_1$$

s.t. $\rightarrow u_1^T u_1 = 1$

$$\Rightarrow L(u, \lambda) = u_1^T S u_1 - \lambda(u_1^T u_1 - 1)$$

متغیرهای سازین معادله
ضریب لاجرانژی

$$\Rightarrow \boxed{S u_1 = \lambda u_1}$$

$$\Rightarrow \frac{\partial L}{\partial u_1} = 0 \rightarrow \frac{\partial L}{\partial u_1} = 2S u_1 - 2\lambda u_1 + 0 = 0$$

$$\boxed{A u = \lambda u}$$

بردارها
متغیرها

$$\Rightarrow \cancel{2} S u_1 = \cancel{2} \lambda u_1$$

$$\Rightarrow \boxed{[u, \lambda]} = \operatorname{eig}(A)$$

کانال تلگرام: @onlinebme

$$\Rightarrow u = ?$$

$$y = u^T x$$

الگوریتم خلاصه شده برای پیاده سازی PCA

تعداد ویژگی ها $\downarrow$ $X = d \times N$

$$\underline{\mu} = d \times 1$$

$$X_n = X - \underline{\mu}$$

0 - تفسیر کردن تعداد بهر فضای جدید
1 - نرمال کردن داده $\Rightarrow \mu_n = 0$

$$S, C_x = X X^T = \text{cov}(X)$$

2 - محاسبه ماتریس کواریانس

$(N \times d)$
 $d \times d = [1 \ 1 \ 1]$

$$[u, \lambda] = \text{eig}(S)$$

3 - تجزیه ماتریس کواریانس به مقادیر ویژه و بردارها ویژه

مقادیر ویژه بردارها ویژه

$$w = u(:, \text{ind})$$

$$w = [1 \ 1 \ 1]$$

$$\lambda = \begin{bmatrix} \lambda_1 & 0 \\ 0 & \lambda_2 \end{bmatrix}$$

$$\lambda = \text{diag}(\lambda)$$

4 - مرتب کردن مقادیر ویژه
 $\text{ind} = \text{sort}(\lambda)$


5 - انتخاب m تا بردار ویژه اول

$$m \times d$$


$$Y = w^T X = m \times N$$

6 - نمایش داده

نحوه حذف redundancy توسط PCA



نحوه کاهش بعد توسط PCA




مفهوم کاهش بعد ویژگی‌ها توسط الگوریتم‌هایی نظیر PCA




Handwritten notes illustrating the PCA transformation:

$$Y = W^T \cdot X$$


where X is the input data matrix and Y is the output matrix. The transformation is shown as $Y = \frac{d \times 1}{\Rightarrow}$ and $Y_m = [$.



چه نیازی به کاهش بعد داریم؟



لغو نیاز



مثال 1: برنامه‌ای بنویسید که در آن با استفاده از الگوریتم **PCA** جهتی که داده در آن ماکزیمم واریانس دارد را پیدا کرده و سپس داده را روی آن نگاشت داده و از فضای دوبعدی به فضای یک بعدی کاهش دهید.

✓ روی داده بدون اینکه کاهش بعدی انجام دهید، بررسی کنید که **PCA** چه تاثیری روی فضای ویژگی می‌گذارد و همچنین بررسی کنید که ماتریس کواریانس داده در فضای جدید به چه صورت است.

$$\mu = \begin{bmatrix} 0 \\ 0 \end{bmatrix}, \quad C = \begin{bmatrix} 3 & 5 \\ 5 & 14 \end{bmatrix}$$

→ *mnvnc*

$$\begin{bmatrix} 1 & 1 & 1 \end{bmatrix}_{d \times N}$$

X_{train}

$f \cdot m$




تابع تبدیل

W

$$\rightarrow W^T X$$

مثال 2: برنامه‌ای بنویسید که در آن با استفاده از الگوریتم **PCA** از فضای دوبعدی به فضای یک بعدی کاهش


دهید و بررسی بینید که آیا داده‌های دو کلاس در فضای یک بعدی همچنان تفکیک پذیر هستند؟!




$$\mu_1 = \begin{bmatrix} -4 \\ 0 \end{bmatrix}, \quad C_1 = \begin{bmatrix} 3 & 5 \\ 5 & 14 \end{bmatrix}$$

$$\mu_2 = \begin{bmatrix} 4 \\ 0 \end{bmatrix}, \quad C_2 = \begin{bmatrix} 3 & 5 \\ 5 & 14 \end{bmatrix}$$

PCA → پراکنش بدون ناظر
max




مثال 3: برنامه‌ای بنویسید که در آن با استفاده از الگوریتم **PCA** داده مربوط به اسپایکهای مغزی را از فضای 60 بعدی به فضای 3 بعدی کاهش دهید.




مثال 4: برنامه‌ای بنویسید که در آن با استفاده از الگوریتم **PCA** بردارهای ویژه تصاویر چهره را پیدا کرده و نمایش دهید و بررسی کنید که کدام بردار ویژه بیشترین اطلاعات را دارد.

○ کدام یک از بردارهای ویژه بیشترین اطلاعات را دارد؟



فلوچارت مراحل انجام پروژه یادگیری با ناظر



نحوه استفاده از الگوریتم PCA جهت کاهش بعد در پروژه‌ها

1. تقسیم داده به دو بخش آموزش و تست

2. محاسبه w از روی داده آموزش


3. کدینگ داده تست و آموزش با یک w به دست آمده از طریق

داده آموزش نه ورودی هم



پروژه 1: برنامه‌ای بنویسید که در آن با استفاده از الگوریتم **PCA** ابعاد داده سرطان سینه را کاهش داده سپس با کمک طبقه‌بند **SVM** به دو دسته خوش خیم و بدخیم دسته‌بندی کنید.

① ②



موفق باشید...

نوری زاده چرلو